



به نام خدا



دانشگاه تهران
دانشکده مهندسی برق و کامپیوتر
مدل‌های مولد عمیق
دکتر توسلی‌پور
تمرین اول

نام و نام خانوادگی	علیرضا نجفی مطیعی
شماره دانشجویی	۸۱۰۱۰۰۲۲۴
تاریخ ارسال گزارش	۱۴۰۴.۰۸.۲۰


فهرست

سؤال اول: PGM	۳
بخش اول	۳
بخش دوم	۳
بخش سوم	۵
بخش چهارم	۶
سوال دوم: VAE	۷
بخش اول	۷
بخش دوم	۱۳
مراجع	۱۶

سؤال اول: PGM

بخش اول

زیربخش اول:



شکل ۱. شبکه بیزی متناظر با سوال


زیربخش دوم:

$$P(M, I, T, S, F, D) = P(M)P(S)P(I|S, M)P(F)P(T|F, I)P(D|T, I)$$

زیربخش سوم:

- نادرست چرا که در گراف بین F و D مسیر وجود دارد و مستقل نیستند. (به نوعی F پرنس D است).
- درست است. با دانستن I مسیر بین S و D بلاک می‌شود. (حالت Head-to-Tail)
- درست است چرا که مسیر مستقیم بین M و F وجود ندارد.
- نادرست است. به نوعی حالت explaining why می‌باشد پس مستقل نیستند.
- درست است چرا که با دانستن I مسیر بین M و T بلاک می‌شود.

بخش دوم



شکل ۲. گراف بیزی بخش دوم سوال اول

زیربخش اول:


$$P(C, O, A, S, T, B, M) = P(C)P(O)P(A)P(S|O)P(T|A, O)P(B|S)P(M|B, T, A)$$

زیربخش دوم:

مجموعه تمام والدها و فرزندان و والدین مشترک با فرزندان T مجموعه Markov blanket آن را می سازد که به شکل زیر است:

$$\{O, A, M, B\}$$

زیربخش سوم:



شکل ۳. گراف مارکوف زیربخش سوم بخش دوم

خیر این گراف یک Perfect I-Map برای گراف بی‌زی بالا نیست چرا که برای مثال در گراف قبلی بدون دانستن O، T و A از هم مستقل بودند اما در این گراف مارکوف بین این دو نود مسیر وجود دارد و به همدیگر وابسته شده‌اند. بنابراین تمام استقلال‌های موجود در گراف قبلی در این گراف جدید وجود ندارد و اصطلاحاً Identical نیستند تا Perfect I-Map باشند.

زیربخش چهارم:

خیر. این گراف یک گراف chordal یا وتری نیست. برای مثال در حلقه SBOT مشاهده می‌شود که هیچ وتری وجود ندارد. چون حلقه‌ای با ۴ نود وجود دارد که هیچ وتری ندارد پس این گراف chordal نیست.

زیربخش پنجم:

$$P(A, B, C, M, T, O, S) = \frac{1}{Z} \phi_1(B, T, M) \phi_2(A, T, M) \phi_3(O, T, A) \phi_4(C) \phi_5(O, S) \phi_6(S, B)$$

$$Z = \sum_{a,b,c,m,t,o,s} \phi_1(b, t, m) \phi_2(a, t, m) \phi_3(o, t, a) \phi_4(c) \phi_5(o, s) \phi_6(s, b)$$

زیربخش ششم:

الف) برای بدست آوردن توزیع احتمال توام روی سایر متغیرها باید روی تمامی مقادیر ممکن C (توزیع آن) انتگرال بگیریم. نکته این است که چون C ایزوله است و فرزندی ندارد در عبارت دیگه‌ای به صورت شرطی وجود ندارد بنابراین با توجه به توزیع اولیه داریم:

$$P(C, O, A, S, T, B, M) = P(C)P(O)P(A)P(S|O)P(T|A, O)P(B|S)P(M|B, T, A)$$

$$\rightarrow \int P(C)dC \times P(O)P(A)P(S|O)P(T|A, O)P(B|S)P(M|B, T, A)$$


$$, \int P(C)dC = 1$$

بنابراین با حذف فاکتور $P(C)$ می‌توان توزیع احتمال توام روی سایر متغیرها را بدست آورد.

$$P(A, B, C, M, T, O, S) = \frac{1}{Z} \phi_1(B, T, M) \phi_2(A, T, M) \phi_3(O, T, A) \phi_4(C) \phi_5(O, S) \phi_6(S, B) \quad \text{ب)}$$

مشابه حالت قبلی چون C ایزولست و هیچ فرزندی ندارد اگر انتگرال $\int_{-\infty}^{\infty} \phi(C)dc = 1$ باشد می‌توان با حذف $\phi(C)$ توزیع احتمال توام روی سایر متغیرها را بدست آورد. اگر این انتگرال کاملاً برابر با یک نبود چون روی مقدار $\frac{1}{Z}$ تاثیر می‌گذاشت این گزاره درست نمی‌بود.

بخش سوم



شکل ۴. گراف مربوط به بخش سوم

زیربخش اول:

$$P(A, B, C, D, E, F, G) = \frac{1}{Z} \phi_1(E, G) \phi_2(A, B, C) \phi_3(B, C, D) \phi_4(C, D, F) \phi_5(B, E) \phi_6(E, F)$$

$$Z = \sum_{a,b,c,d,e,f,g} \phi_1(e, g) \phi_2(a, b, c) \phi_3(b, c, d) \phi_4(c, d, f) \phi_5(b, e) \phi_6(e, f)$$

زیربخش دوم:

(a) نادرست است زیرا میان A و G در گراف مسیر وجود دارد. بنابراین بدون وجود شرط این دو متغیر به هم وابسته‌اند.

(b) نادرست است زیرا با دانستن D و C مسیر بین F و A بلاک نمی‌شود و از مسیر E و B به هم راه دارند.

(c) درست است زیرا با دانستن E مسیر بین G و C بلاک می‌شود.

(d) درست است. این عبارت به نحوی بیان دیگر $A \perp E | \{B, C\}$ است که طبق گراف با دانستن B و C مسیر بین A و E بلاک می‌شود.

زیربخش سوم:

با ۵ برابر کردن این تابع پتانسیل در نهایت توزیع احتمال در نهایت تغییری نمی‌کند.

$$\phi'(E, G) = 5 \times \phi(E, G) \rightarrow$$

$$Z = \sum_{a,b,c,d,e,f,g} \phi_1'(e, g) \phi_2(a, b, c) \phi_3(b, c, d) \phi_4(c, d, f) \phi_5(b, e) \phi_6(e, f)$$

$$\rightarrow Z_{new} = 5Z_{old}$$

بنابراین هم صورت و هم مخرج عبارت در ۵ ضرب خواهد شد و در نهایت همدیگر را کنسل خواهند کرد.

بخش چهارم

$$\theta^* = \arg \min_{\mu} KL(q(z) \parallel p(x, z)), p(x, z) = p(x|z)p(z)$$

$$\rightarrow KL(q(z) \parallel p(x, z)) = E_q \left[\log \left(\frac{q(z)}{p(z)p(x|z)} \right) \right] = E_q \left[\log \left(\frac{\theta^2 z e^{-\theta z}}{e^{-z} z e^{-zx}} \right) \right] =$$

$$E_q [\log(\theta^2) - \theta z + z + zx] = \log(\theta^2) - \theta \times \frac{2}{\theta} + \frac{2}{\theta} (1 + x)$$

$$\frac{dKL}{d\theta} = 0 \rightarrow \frac{2\theta}{\theta^2} - \frac{2(1+x)}{\theta^2} = 0 \rightarrow \theta - (1+x) = 0 \rightarrow \theta = 1+x$$

زیربخش اول:

$$E_{q(z|x)}[\log(p(x|z))] - D_{KL}(q(z|x) \parallel p(z))$$


به این دلیل به طور مستقیم احتمال درست‌نمایی داده‌ها را افزایش نمی‌دهیم چون محاسبه $p(x)$ در عمل بسیار سخت یا حتی غیر ممکن است.

$$p(x) = \int p(x, z) dz = \int p(x|z)p(z) dz$$

محاسبات این انتگرال باید در تعداد بعد بالا و معمولاً پیوسته صورت بگیرد که کار راحتی نیست. برای همین از یک کران پایین یا ELBO که همان رابطه بالاست استفاده می‌کنیم و سعی می‌کنیم آن را مکسیموم کنیم. ترم اول در این عبارت مربوط خطای بازسازی (Reconstruction Loss) و ترم دوم مربوط به رگولاریزیشن فضای فضای latent است. در واقع ترم اول شباهت میان نمونه اصلی و نمونه تولید شده را بررسی می‌کند و ترم دوم تلاش می‌کند تا توزیع های تولید شده توسط انکودر تا حد امکان شبیه به توزیع نرمال استاندارد باشد.

زیربخش دوم:

این دیتاست مجموعه‌ای از تصاویر دو بعدی است که به منظور بررسی مدل‌هایی مانند VAE گردآوری شده‌است و disentanglement را در مدل‌های unsupervised بررسی می‌کند. این دیتاست شامل ۷۳۷۲۸۰ عدد تصویر باینری 64*64 است. حال با استفاده از توضیحات داده شده در فایل کمکی موجود در github نمونه‌هایی از تصاویر موجود در این دیتاست را لود می‌کنیم:



شکل ۵. نمونه‌هایی از تصاویر موجود در دیتاست

زیربخش سوم:

راه حل موجود برای حل این مشکل استفاده از Reparametrization Trick است. در حالت عادی انکودر


z را مستقیماً به خروجی نمی‌دهد، بلکه پارامترهای آن توزیع را به عنوان خروجی می‌دهد. سپس با نمونه‌برداری از آن توزیع z را می‌گیریم. چون نمونه‌برداری به صورت تصادفی انجام می‌پذیرد، نمی‌توان از z مشتق گرفت. بنابراین زنجیره گرادیان‌ها در اینجا قطع خواهد شد. برای رفع این مشکل یک ϵ از توزیع گوسی استاندارد نمونه‌برداری می‌کنیم و سپس با توجه به میانگین و واریانس خروجی از انکودر آن را اسکیل می‌کنیم. بنابراین z به شکل زیر درمی‌آید:

$$z = \mu + \sigma \times \epsilon$$

حال با توجه به تعریف جدید z می‌توان از آن نسبت به μ یا σ مشتق گرفت و زنجیره گرادیان دیگر قطع نخواهد شد.

زیربخش چهارم:

با توجه به جداول ۱ و ۲ موجود در صورت پروژه لایه‌ها و هایپرپارامترها را تنظیم می‌کنیم و برای ترینینگ بهتر Reparametrization Trick را هم لحاظ می‌کنیم. در نهایت نمودار توابع هزینه نسبت به هر epoch به صورت زیر در می‌آید. همانطور که مشاهده می‌شود تمرکز مدل بیشتر روی کاهش خطای بازسازی بوده که این موضوع باعث بوجود آمدن مدل‌هایی مانند $\beta - VAE$ در حالت‌های پیشرفته‌تر و در سیر پیشرفتی این مدل شده‌است.



شکل ۶. نمودارهای مربوط به توابع هزینه در طول آموزش

بازسازی این مدل را نیز با ۸ تصویر می‌سنجیم که نتیجه به صورت زیر است:



شکل ۷. نمونه تصاویر اصلی و بازسازی شده

مشاهده می‌شود که در تصاویر بازسازی‌شده مدل محتوای معنایی کلی را تا حد خوبی یاد گرفته است. تقریباً در تمامی جفت‌ها مدل به خوبی شکل، مکان حدودی در صفحه و اندازه نسبی را بازسازی کرده اما مشکل اصلی که قابل مشاهده است این است که تمامی تصاویر بازسازی شده تاری هستند. این به این خاطر است که ما زمانی که از یک تابع هزینه مانند BCE برای بخش بازسازی استفاده می‌کنیم، این خطا به صورت پیکسل به پیکسل اندازه‌گیری می‌شود و مدل برای کاهش کلی خطا به خصوص در لبه‌ها تاری یا ترکیب پیکسلی سیاه و سفید در پیکسل‌های نزدیک هم را به کار می‌گیرد. همچنین توزیع نرمال استاندارد انتخابی احتمالاً توزیع بسیار ساده‌ای است و برای بهبود کیفیت احتمالاً باید از توزیع‌های پیچیده‌تری استفاده کرد.


زیربخش پنجم:

در حالت $\beta = 1$ (حالت اولیه) مدل VAE تمرکز خود را بیشتر روی کم کردن خطای بازسازی خواهد گذاشت و به همین دلیل تا حدودی وضعیت فضتی نهان را نادیده خواهد گرفت. این امر موجب خواهد شد تا فضای نهان ما به یک فضای درهم تنیده تبدیل شود. این به این معناست که اگر برای مثال ما ۶ بعد برای ویژگی‌های مختلف تصاویر در فضای نهان در نظر گرفته باشیم، این بعدها به خوبی از هم تفکیک نخواهند شد و برای مثال z_1 می‌تواند روی دو ویژگی تأثیر بگذارد. با در نظر گرفتن $\beta > 1$ ، تأثیر ترم KL را افزایش می‌دهیم. بنابراین مدل مجبور خواهد شد تا توزیع $q(z|x)$ را به توزیع گوسی استاندارد نزدیک‌تر کند. بنابراین مدل بهتر متوجه می‌شود که هر بعد در فضای نهان مربوط به کدام ویژگی است و فضای نهان یک فضای تفکیک‌شده خواهد شد. البته چون با این کار تمرکز مدل بیشتر روی منظم‌سازی فضای نهان می‌رود احتمالاً مدل در بازسازی کیفیت بدتری از خود نشان خواهد داد.


زیربخش ششم:

برای دو بتای ۲ و ۲۰ دو مدل را آموزش می‌دهیم که نمودارهای مربوط به توابع هزینه و همچنین تصاویر بازسازی‌شده به صورت زیر است:

* در رسم توابع هزینه ترم KL بدون احتساب ضریب β ترسیم شده و β در ترسیم تابع هزینه مجموع حساب شده است.




شکل ۸. نمودارهای مربوط به خطا ($\beta = 2$)




شکل ۹. تصاویر بازسازی شده ($\beta = 2$)

مشاهده می شود که بازسازی نسبت به مدل پایه بدتر شده است و نسبت به حالت عادی میزان تاری افزایش یافته و همچنین به صورت کلی بازسازی ساختاری اشکال نیز اندکی بدتر شده است. در واقع چون با ضریب بتا سهم بیشتری برای خطای KL قائل شده ایم مدل یک راه ساده برای کاهش این خطا پیدا کرده و درواقع در هر بازسازی، به سمت بازسازی همان توزیع نرمال استاندارد رفته و با افزایش بتا احتمالا بیشتر به این سمت حرکت خواهیم کرد.



شکل ۱۰. نمودارهای مربوط به خطا $\beta = 20$



شکل ۱۱. نمونه تصاویر اصلی و بازسازی شده

مشاهده می‌شود که مطابق انتظار با افزایش بتا تصاویر تارتر و خیلی نزدیک‌تر به بازسازی همان توزیع نرمال استاندارد شده‌اند. این نشان می‌دهد که بتای ۲۰ جریمه خطای KL را بسیار زیاد کرده است.

زیربخش هفتم:

MIG یا Mutual Information Gap یک معیار ارزیابی برای ارزیابی میزان مستقل بودن ابعاد فضای نهان است. به عبارت ساده‌تر مشخص می‌کند که آیا یک مدل توانایی این را دارد تا فاکتورهای اصلی و واقعی داده‌ها را به خوبی از هم تفکیک کند و در هر یک از بعدهای فضای نهان قرار دهد؟ در ابتدا این معیار اطلاعات متقابل میان هر بعد فضای نهان و فاکتور واقعی آن را محاسبه می‌کند $(I(z_i; k))$. اگر این مقدار بالا باشد هر بعد فضای نهان اطلاعات خوبی راجع به K دارد. سپس برای هر فاکتور واقعی بررسی می‌کند که کدام بعد فضای نهان بیشترین اطلاعات متقابل را با آن دارد. سپس دومین بعد فضای نهان که دارای این ویژگی است را پیدا می‌کند. امتیاز فاصله یا گپ از اختلاف $I(z_{first}; k) - I(z_{second}; k)$ بدست می‌آید. سپس این مقدار

نسبت به کلیت داده‌ها نرمالایز می‌شوند. اگر مقدار MIG برای یک فاکتور بالا باشد یعنی یکی از ابعاد فضای نهان می‌تواند به خوبی این فاکتور را انکود کند و بقیه ابعاد فضای نهان نباید خیلی در مورد آن فاکتور خوب عمل کنند.

```


--- Model MIG Score Comparison ---

```

Factor	VAE (beta=1)	Beta-VAE (beta=2)	Beta-VAE (beta=20)
shape	0.0397	0.0228	0.0331
scale	0.0657	0.0644	0.0738
orientation	0.0025	0.0009	0.0022
posX	0.0198	0.0444	0.0276
posY	0.0102	0.0860	0.0775
Average MIG	0.0276	0.0437	0.0428

شکل ۱۲. مقایسه مقادیر MIG برای سه مدل

مشاهده می‌شود که مطابق با انتظار مدل پایه بیشترین میزان درهم‌تنیدگی در فضای نهان را دارد و در این مورد از دو مدل دیگر عملکرد بدتری داشته‌است چرا که تمرکز این مدل بیشتر روی بازسازی است. اما مقدار MIG برای دو مدل دیگر نیز چندان بالا نیست و همچنین تمامی مدل‌ها در فاکتور Orientation عملکرد فاجعه‌ای دارند و posY برای مدل‌های بتا و Scale برای مدل پایه بهترین بوده‌اند. پایین بودن مقدار MIG برای مدل‌های بتا می‌تواند دلایلی داشته باشد. یکی از مهم‌ترین دلایل می‌تواند این باشد که برای آموزش یک مدل VAE به تعداد epoch بسیار بیشتری نیاز است و همچنین بهتر است که در تعداد دوره بالا از نرخ یادگیری متغیر نیز استفاده کرد. همچنین دلیلی که با افزایش بتا MIG افزایش نیافته این است که مقدار دوم انتخابی یعنی ۲۰ بیش از حد جریمه خطای ترم KL را زیاد کرده و مقدار بهینه برای بهترین MIG به احتمال بالا مقدار کوچکتري از ۲۰ خواهد بود. از آنجایی که پیدا کردن بتای ایده‌آل و همچنین بهبود کلی مدل در صورت پروژه درخواست نشده و همچنین فرآیند آموزش VAE بسیار زمانبر است گامی در این راستا برداشته نشد اما مشخصاً نیاز به آموزش در تعداد بالاتری دوره و عوض کردن هایپرپارامترها در مرحله اول و سپس در صورت عدم بهبود معنادار عوض کردن معماری است.



شکل ۱۳. نمودار مولفه‌ها برای مدل با $\beta = 20$

نتایج این بخش نیز تایید می‌کند که فضای نهان z تقریباً هیچ اطلاعاتی از تصویر ورودی را شامل نمی‌شود که با نتایج بخش قبل و MIG پایین مدل با بتای ۲۰ همخوانی دارد. درواقع این مدل یک نمونه کامل نشان‌دهنده posterior collapse است، یعنی انکودر بجای تولید تصاویر معنی‌دار همواره چیزی نزدیک به همان توزیع نرمال استاندارد را تولید می‌کند. نتایج این بخش نیز این موضوع را تایید می‌کند که بتای ۲۰ جریمه زیادی برای ترم KL ایجاد کرده است. راهکارهای بخش قبل در بهبود این موضوع می‌تواند موثر باشد.

بخش دوم

زیربخش اول:

تفاوت اصلی میان این مدل با حالت عادی VAE این است که در VQ-VAE از یک فضای نهان گسسته بجای فضای نهان پیوسته استفاده می‌کنیم. در حالت اولیه انکودر با دریافت یک ورودی x ، پارامترهای یک توزیع پیوسته که معمولاً توزیع گاوسی است را یعنی میانگین و واریانس آن را به ما می‌دهد. سپس نمونه‌برداری از آن توزیع اتفاق می‌افتد و فضای نهان در این حالت بطور کلی یک فضای چندبعدی و پیوسته خواهد بود. در مدل VQ-VAE انکودر پس از دریافت ورودی x ، یک بردار نهان $z_e(x)$ را خروجی می‌دهد. پس از آن بجای نمونه‌برداری از توزیع این مدل از یک مجموعه محدود و گسسته از یکسری بردارهای پیش‌تعریف‌شده (Embedding) که مثلاً شامل k بردار هستند استفاده می‌کند. این مدل بردار $z_e(x)$ بدست آمده را با نزدیک‌ترین بردار موجود در این محدوده (براساس فاصله اقلیدسی) جایگزین می‌کند و در نهایت

دیکودر این بردار گسسته جایگزین شده را دریافت می‌کند. در واقع گسسته‌سازی همین فرآیند است که در آن خروجی پیوسته انکودر به یکی از k گزینه موجود گسسته تبدیل می‌شود. به این ترتیب فضای نهان فورس می‌شود تا به جای نمایش بی‌نهایت حالت پیوسته، تنها یکی از k حالت گسسته را انتخاب کند. اما در این حالت عملیات پیدا کردن نزدیک‌ترین بردار مشتق‌پذیر نیست و زنجیره گرادیان را قطع خواهد کرد. این مدل این مشکل را با ترفندی به نام Straight-Through Estimator حل می‌کند که گرادیان را از دیکودر به انکودر کپی می‌کند. این مدل دو مزیت اصلی نسبت به حالت پایه دارد.

(۱) در مدل پایه اگر از یک دیکودر قوی استفاده شود، این امکان وجود دارد که یاد بگیرد تا بردار نهان z را کاملاً نادیده بگیرد و خودش به تنهایی داده‌ها را مدل کند. در این حالت ترم KL در تابع هزینه به صفر میل می‌کند و فضای نهان هیچ اطلاعات مفیدی یاد نمی‌گیرد. به این پدیده *posterior collapse* گفته می‌شود. در حالت VQ-VAE چون فضای نهان گسسته است و دیکودر فقط یکی از k بردار را دریافت می‌کند، مجبور است از این اطلاعات استفاده کند و دیکودر نمی‌تواند z را نادیده بگیرد چرا که z تنها ورودی‌ای است که اطلاعات سطح بالا در مورد تصویر را به آن می‌دهد. این کار مدل را وادار به یادگیری یک فضای نهان عالی و مفید می‌کند.

(۲) در VQ-VAE چون فضای نهان گسسته بسیار ساختاریافته است، این به ما اجازه می‌دهد که یک مدل مولد دوم و بسیار قدرتمند (مثل یک Transformer) را روی این فضای نهان گسسته آموزش دهیم تا کدهای جدید تولید کند. مدل ابتدا یاد می‌گیرد که چگونه تصاویر را به کدهای گسسته فشرده کند و سپس یاد خواهد گرفت که چگونه کدهای جدید که شبیه کدهای واقعی هستند را تولید کند.

زیربخش دوم:

تلاش مقاله VampPrior در جایگزین کردن توزیع نرمال استاندارد با یک توزیع جدید و انعطاف‌پذیر است که از خود داده‌ها یاد گرفته می‌شود. بنابراین بجای یک توزیع ساده مدل ترکیبی از توزیع‌های مختلف را در نظر خواهد گرفت. این مدل مجموعه‌ای از *prototypical inputs* را یاد می‌گیرد که *pseudo-inputs* نامیده می‌شوند. در این حالت توزیع هدف دیگر یک توزیع ساده مانند نرمال استاندارد نیست بلکه ترکیبی از خروجی‌های انکودر برای این *prototypical inputs* است. استفاده از یک توزیع هدف انعطاف‌پذیر در این مدل به جای یک توزیع ساده نرمال استاندارد منجر به استفاده بهتر از متغیرهای نهان خواهد شد. بزرگترین ایراد توزیع نرمال استاندارد این است که اکثر اوقات مدل را مجبور می‌کند تا متغیرهای نهان را به طور کامل نادیده بگیرد که همان *posterior collapse* است. چون در اینجا هدف اصلی این مدل تطابق بهتر با شکل واقعی و پیچیدگی‌های داده‌های کدگذاری شده است و هدف دیگر خیلی ساده نیست، انکودر نیازی ندارد تا برای بهبود

خطا اطلاعات خود را دور بریزد. در نتیجه با داشتن یک توزیع انعطاف‌پذیر از متغیرهای نهان استفاده موثرتری خواهد شد و عملکرد مدل بهبود خواهد یافت.

زیربخش سوم:

مدل SC-VAE (Sparse Coding-based Variational Autoencoder): در مدل پایه فرض اصلی این است که متغیرهای فضای نهان یا همان z از توزیع نرمال استاندارد پیروی می‌کنند اما مدل SC-VAE فرض می‌کند داده‌ها می‌توانند توسط ترکیبی از ویژگی‌های پایه ساخته شوند. برای همین توزیع را یک توزیع مانند توزیع لاپلاس در نظر می‌گیرد تا توزیع تنک باشد به این معنی که اکثر مقادیر z صفر باشند و تعداد کمی از آن‌ها دارای مقادیر غیرصفر باشند. همچنین روش ISTA یک روش ریاضی استاندارد برای حل مسائل کدگذاری تنک است. هدف از بکارگیری این الگوریتم پیدا کردن برداری برای z است که هم تنک باشد و هم توانایی این را داشته باشد تا x را به خوبی بازسازی کند. در SC-VAE از نسخه LISTA که نسخه یادگیری شده این الگوریتم است در انکودر استفاده می‌شود. همچنین ساختار انکودر به صورت Recurrent ساخته می‌شود. نقش اصلی ISTA در واقع اعمال یک تابع غیرخطی به نام soft-thresholding است. این تابع مقادیر کوچک مثل نویزها و ویژگی‌های با اهمیت کمتر را صفر و سایر مقادیر را نگه می‌دارد. همچنین در حالت معمول اجرای الگوریتم ISTA زمان زیادی می‌گیرد اما در این مدل شبکه عصبی موجود یاد می‌گیرد تا تکرارهای موجود در این الگوریتم را در تعداد محدودی از لایه‌ها تقریب بزند و سرعت را افزایش دهد. بنابراین نقش اصلی ISTA در تولید یک بردار نهایی تا جای ممکن تنک در انکودر است. حال به مزایای تنک بودن بازنمایی‌های نهان می‌پردازیم. در مدل پایه اطلاعات یک ویژگی می‌توانند در تمام ابعاد z پخش شوند اما در SC_VAE چون اکثر ابعاد صفر هستند بعدهای غیر صفر معمولاً متناظر با ویژگی‌های و معنایی مشخصی از داده هستند که باعث تقویت Disentanglement می‌شود. همچنین مشاهده شد که مدل پایه تصاویر را بصورت تار بازسازی می‌کند که در این مورد هم تنک بودن باعث تمرکز بیشتر مدل روی ویژگی‌های مهم‌تر می‌شود و جزئیات غیرضروری را حذف کند که معمولاً بازسازی را بهتر و شفاف‌تر خواهد کرد. دیگر ویژگی این است که در این مدل برای توصیف داده به جای استفاده از یک بردار پر از اعداد اعشاری مانند مدل پایه، تنها از چند ویژگی کلیدی استفاده می‌شود که همانند پردازش اطلاعات در مغز انسان عمل می‌کند. همچنین این ساختار تنک و استفاده از الگوریتم ISTA مدل را مجبور می‌کند تا از متغیرهای نهان استفاده کند و نمی‌تواند آن‌ها را به سادگی نادیده بگیرد.

- 1: Chen, R. T. Q., Li, X., Grosse, R. B., & Duvenaud, D. (2018). Isolating sources of1 disentanglement in variational autoencoders. In Advances in Neural Information Processing Systems (NeurIPS 2018).
- 2: van den Oord, A., Vinyals, O., & Kavukcuoglu, K. (2017). Neural discrete representation learning. In Advances in Neural Information Processing Systems (NeurIPS 2017).
- 3: Tomczak, J. M., & Welling, M. (2018). VAE with a VampPrior. In Proceedings of the Twenty-First International Conference on Artificial Intelligence and Statistics (AISTATS 2018) (Vol. 84, pp. 1214-1223). PMLR.
- 4: Xiao, P., Qiu, P., Ha, S., Bani, A., Zhou, S., & Sotiras, A. (2024). Sparse Codingbased Variational Autoencoder with Learned ISTA (SC-VAE). Pattern Recognition, 161, Article 111187.